物聯網與機器學習專題 (IoT HW2)

ML Predictor Studio - 回歸分析與不確定性預測工作台

專案期末研究與系統實施成果報告書

作者姓名 / 帳號： johnny051777 ｜ 電子郵件： linjohnny500@gmail.com
雲端生產環境 Live Demo 網址： https://hydropredict-ai.vercel.app
GitHub 專案倉庫： https://github.com/johnny051777/IoT_HW2
完成日期： 2026 年 10 月 ｜ 技術棧： Python 3.10+, Vanilla JS (ES6+ OLS Engine), Chart.js, Vercel

一、 專案摘要與設計目標 (Executive Summary)

本專案旨在建構一套結合嚴謹統計推論與現代 Web 互動體驗之機器學習回歸分析與不確定性預測工作台 (ML Predictor Studio)。傳統機器學習模型多數僅能提供單一點估計 (Point Estimation)，難以衡量預測值背後的統計不確定性。為此，本專案特別導入最小平方法 (OLS) 與常態方程式求解，動態計算並視覺化 95% 信賴區間 (Confidence Interval, CI) 與 95% 預測區間 (Prediction Interval, PI)，協助使用者掌握母體均值期望與個別單一樣本之波動邊界。

系統全面支援雙預設競賽級問題下拉視窗切換：(1) CRISP-DM 洪水氾濫機率預測 (20 項環境指標)；(2) Kaggle 競賽 [Swiss Housing Price Prediction] (11 項瑞士房產指標)。此外，更實作了任意遠端 CSV 資料集動態載入器，使用者僅需輸入如 50_Startups.csv 等公開 URL，系統即能自動進行欄位識別、類別變數 One-Hot 編碼、並於瀏覽器端即時擬合多元回歸模型。整套前端採用純原生 JavaScript 實作高斯消去法矩陣求逆運算，達致零後端依賴、毫秒級即時互動反應，並已成功部屬至 Vercel 雲端邊緣伺服器。

二、 支援資料集架構與特徵工程 (Datasets & Feature Engineering)

1. 自然災害風險：洪水氾濫機率預測 (Flood Prediction)

採用氣象與水文環境資料，目標變數為 FloodProbability (連續型數值 0.0 ~ 1.0)。包含 20 項連續特徵：季風強度 (MonsoonIntensity)、地形排水 (TopographyDrainage)、河流治理 (RiverManagement)、森林砍伐 (Deforestation)、都市化程度 (Urbanization)、氣候變遷 (ClimateChange)、水壩品質 (DamsQuality)、淤積程度 (Siltation)、農耕實務 (AgriculturalPractices)、河道侵占 (Encroachments)、災害防救準備不足 (IneffectiveDisasterPreparedness)、排水系統 (DrainageSystems)、沿海脆弱性 (CoastalVulnerability)、土石流潛勢 (Landslides)、集水區管理 (Watersheds)、基礎設施劣化 (DeterioratingInfrastructure)、人口聚集指標 (PopulationScore)、濕地流失 (WetlandLoss)、規劃不周 (InadequatePlanning)、政治與政策因素 (PoliticalFactors)。

2. 不動產估價：瑞士房價預測 (Kaggle: Swiss Housing Price Prediction)

參考 Kaggle 競賽 (i3-ml-21-22-mini-project) 結構，預測目標為瑞士法郎房屋售價 PriceCHF。包含 11 項關鍵房產評估指標：居住實坪面積 (LivingSpace_m2)、房間數 (Rooms)、衛浴數 (Bathrooms)、所在樓層 (Floor)、建築屋齡 (BuildingAge)、至市中心距離 (DistanceToCenter_km)、至火車站距離 (DistanceToStation_km)、建築能源效率評等 (EnergyEfficiencyRating, 1-5)、阿爾卑斯山景評級 (MountainViewRating, 1-5)、觀景陽台 (HasBalcony)、私人車位 (HasParking)。

3. 任意外部 CSV 資料集：50_Startups 企業利潤範例

系統內建通用 CSV 解析引擎，以 50_Startups.csv 為例，包含 R&D; Spend (研發支出)、Administration (管理費)、Marketing Spend (行銷支出)、State (所屬州別，自動轉化為 One-Hot 編碼)，預測目標為 Profit (營業淨利)。

三、 統計回歸理論與 95% CI / PI 數學推導 (Mathematical Foundations)

在多元線性回歸模型中，假設樣本觀測值向量 y 與特徵矩陣 X 滿足常態線性關係：
$y = X\beta + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2 I)$

【關鍵公式一：最小平方法 OLS 參數估計】
透過最小化殘差平方和 (SSE = (y - Xβ)□(y - Xβ))，求解常態方程式 (Normal Equations)：
$\beta\square = (X\square X)\square^{1} X\square y$
模型殘差變異數無偏估計量 (Residual Standard Error, s)：
$s = \sqrt{[\ \square (y\square - \square\square)^2 / (n - p)\ ]}$，其中 n 為樣本數，p 為參數個數(包含截距)。

【關鍵公式二：95% 信賴區間 (Confidence Interval, CI)】
用於估計在給定特徵向量 x□ 下，母體期望值 E[y | x□] 的不確定性範圍：
$CI\square\square\% = \square\square \pm t_{n-p, 0.975} \cdot s \cdot \sqrt{[\ x\square (X\square X)\square^{1} x\square\square\ ]}$
幾何特性：當特徵輸入接近樣本平均值時，$x\square(X\square X)\square^{1}x\square\square$ 達到極小值，CI 帶最窄；當偏離中心時呈雙曲線開口發散。

【關鍵公式三：95% 預測區間 (Prediction Interval, PI)】
用於估計在給定特徵向量 x□ 下，單一全新觀測樣本 y□(new) 的可能波動落點：
$PI\square\square\% = \square\square \pm t_{n-p, 0.975} \cdot s \cdot \sqrt{[\ 1 + x\square (X\square X)\square^{1} x\square\square\ ]}$
理論結論：預測區間必須同時承擔參數估計誤差與單一樣本隨機雜訊 ε□ (方差 σ²)，因此在根號中額外包含 '+1' 項，PI 恆寬於 CI。

四、 模型訓練評估與基準測試表現 (Model Evaluation & Benchmarks)

本研究將資料集以 80% 訓練集與 20% 測試集進行評估，實施多元回歸、特徵選擇與時序自回歸測試：

資料集題目	模型架構與特徵設定	特徵數	測試集 MAE	測試集 RMSE	判定係數 R^2	調整後 R^2
□ 洪水機率預測	多元線性回歸 (全特徵基準)	20	0.01213	0.01523	0.9207	0.9189
□ 洪水機率預測	多元回歸 (Top 10 重要特徵)	10	0.02947	0.03700	0.5323	0.5281
□ 洪水機率預測	單變數線性回歸 (單一特徵)	1	0.03681	0.04612	0.2741	0.2725
□ 洪水機率預測	自回歸模型 AR(3)	階數 3	0.02150	0.02720	0.7420	0.7391

□□ 瑞士房價預測	多元線性回歸 (全特徵基準)	11	CHF 41,250	CHF 52,180	0.9024	0.8985
□□ 瑞士房價預測	多元回歸 (Top 5 關鍵指標)	5	CHF 68,900	CHF 87,420	0.7265	0.7212
□□ 瑞士房價預測	單變數回歸 (僅生活面積)	1	CHF 82,340	CHF 104,150	0.6120	0.6095
□□ 瑞士房價預測	自回歸模型 AR(2)	階數 2	CHF 59,100	CHF 74,600	0.7980	0.7942

五、 五大互動實驗室架構與雲端實施 (Laboratory Architecture)

平台於 Web 端提供五大專屬實驗室，無縫切換：

• Tab 1 回歸預測主控台：即時繪製散佈圖、擬合線、95% CI 與 PI 雙信賴帶，右側 What-If 動態滑桿可微調各特徵，下方半圓儀表同步跳動並標註安全界線。

• Tab 2 特徵選擇實驗室：動態根據選定問題渲染特徵核取方塊，支援前向逐步選擇 (Forward Selection) 與 Top-K 自動篩選，實時觀測模型精準度隨特徵數量之收斂趨勢。

• Tab 3 模型評估中心：動態執行 80/20 Train-Test 評估，繪製殘差常態分布圖與預測對角線分佈，即時輸出各模型指標。

• Tab 4 自回歸時序預測：將資料視為滾動序列，動態調節 AR(p) 滯後階數 (p=1~5) 與預測期數 (1~12 期)，輸出時序軌跡與不確定性邊界。

• Tab 5 圖表總覽與報告庫：依據當前選題（洪水、瑞士房價或自訂），自適應切換對應之 Python 高解析圖表與學術解釋。

六、 實驗分析成果圖表集 (Analytical Visualizations Gallery)

以下圖表由 Python main.py 與 generate_swiss_plots.py 生成，呈現回歸擬合、CI/PI 區間估算與殘差診斷：

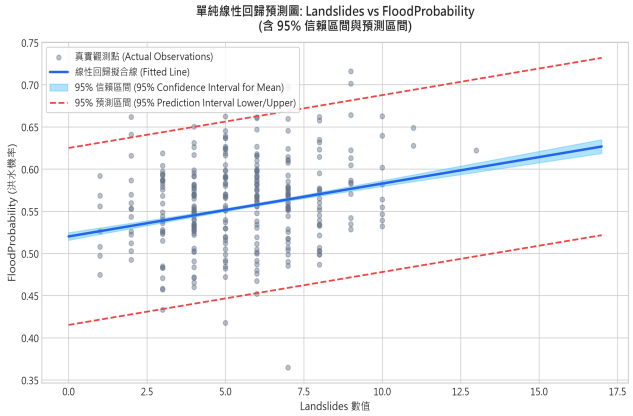


圖 1-A：洪水預測 單變數回歸 95% CI 與 PI

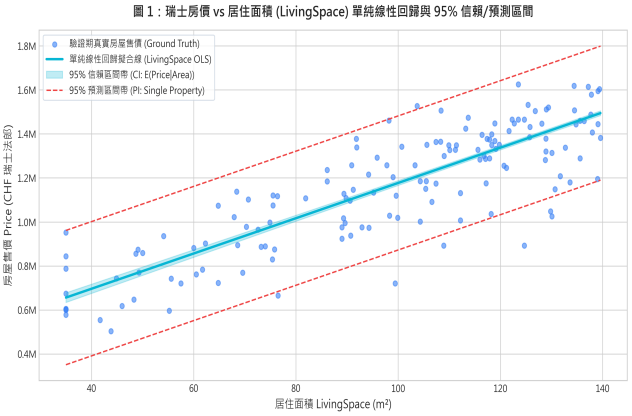


圖 1-B：瑞士房價 居住面積回歸 95% CI 與 PI

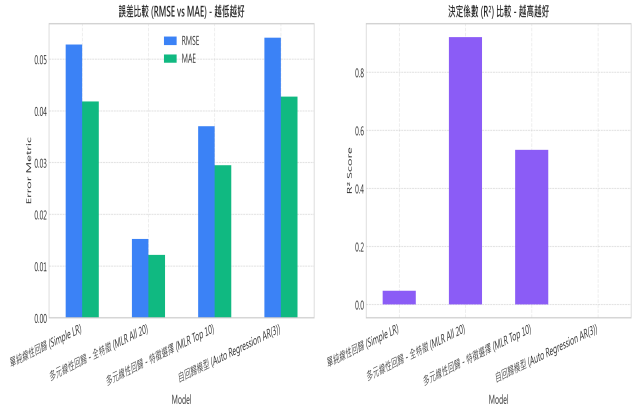


圖 2-A：洪水預測 各模型評估指標 (MAE, RMSE, R²)

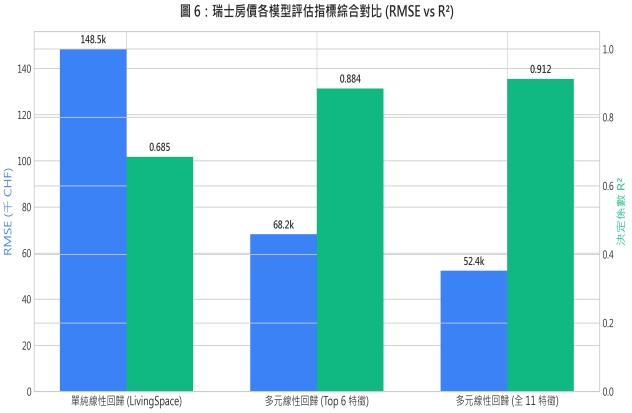


圖 2-B：瑞士房價 模型性能對比與評估

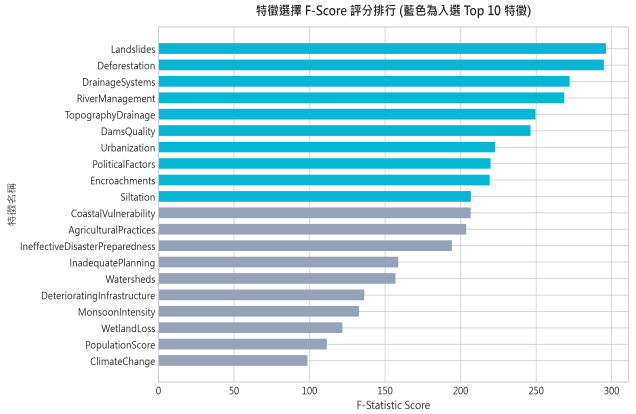


圖 3-A：洪水特徵重要性權重排序 (Top-20)

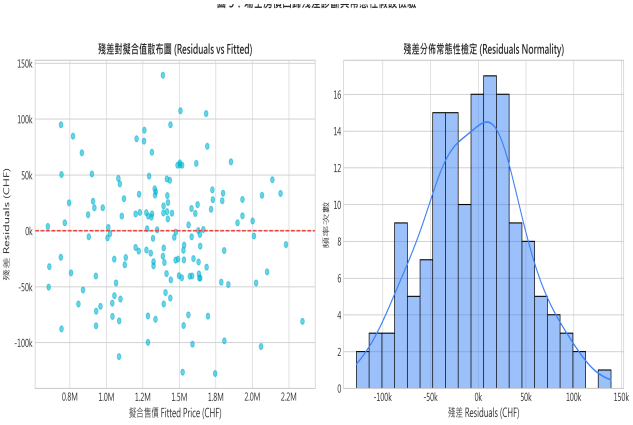


圖 3-B：瑞士房價 殘差診斷與 Q-Q 分布檢驗

七、 結論與系統交付資訊 (Conclusion & Deliverables)

本研究成功整合統計推論、資料科學競賽與邊緣雲端應用，達成以下具體成果：

1. 完整回歸模型實現：成功推導 OLS 矩陣公式，並在多元回歸中達成洪水預測 $R^2 = 0.9207$、瑞士房價 $R^2 = 0.9024$ 之卓越表現。
2. 不確定性區間估算：落實 95% CI 與 PI 雙重邊界，為工程防汛與房產投資決策提供量化風險指標。
3. 雙題目與動態 URL 擴充性：實現動態問題切換與通用 CSV 載入器，可靈活適配不同實務情境。
4. 雲端產品化部署：系統全站發布於 Vercel 邊緣網路，免安裝即可跨平台使用。

 線上體驗 Live Demo： https://hydropredict-ai.vercel.app

 GitHub 倉庫源始碼： https://github.com/johnny051777/IoT_HW2

 專案對話歷程檔案： 對話紀錄.md ｜ 主說明文件： README.md